



Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación
CC3084 Data Science, Semestre II 2026

Laboratorio 1

Series de Tiempo

Fernando Rueda - 23748
Fernando Hernández - 23645

Guatemala, julio de 2026

Índice

1. Introducción	2
2. Análisis exploratorio	2
2.1. Calidad de los datos	2
2.2. Comportamiento temporal	2
2.3. Comportamiento durante y después de la pandemia	3
2.4. Valores atípicos	4
2.5. Países, regiones, vías y fronteras	5
3. Construcción de series y partición	6
4. Análisis y modelado por serie	7
4.1. Procedimiento común	7
4.2. Resultados del modelado	9
5. Análisis comparativo	10
5.1. Regiones	10
5.2. Fronteras	11
5.3. Hallazgos para el INGUAT	11
6. Conclusiones	12

1. Introducción

Trabajamos con los datos históricos de ingreso de viajeros internacionales a Guatemala, de enero 2009 a junio 2026. El conjunto viene en formato largo, una fila por combinación de mes, vía, frontera, país, agrupación de residencia y tipo de viajero, con la cantidad de personas en la columna de la medida. Son 161036 filas y 210 meses consecutivos, sin huecos.

El objetivo del laboratorio es explorar el conjunto, construir series de tiempo mensuales, analizar su comportamiento y modelarlas para predecir. Elegimos como medida a los visitantes, que son la suma de turistas y excursionistas, porque es la única agregación comparable en todo el rango. La categoría Viajero cambia de definición en 2023 y los cruceristas desaparecen ese mismo año, así que ninguna de las dos sirve para comparar los 210 meses.

Todo el procesamiento se organizó como un pipeline de etapas, cada una lee la salida de la anterior, la valida y escribe su propio archivo. El código está en el repositorio y no se incluye aquí, este informe recoge solo los resultados y su lectura.

2. Análisis exploratorio

2.1. Calidad de los datos

El conjunto no tiene valores faltantes ni filas duplicadas exactas. El único campo con nulos es el código de frontera, y es por diseño, queda vacío para la categoría Cruceros que no es una frontera física. Lo que sí encontramos fue inconsistencia de categorías. Trece países venían escritos de dos formas que solo difieren en mayúsculas, por ejemplo Federación de Rusia y Federación De Rusia, concentradas en el tramo 2020 y 2021. Sin unificarlas, un mismo país se cuenta dos veces y el ranking queda partido. La limpieza las fusionó eligiendo la variante más frecuente. También reetiquetamos dos códigos sin traducir y unificamos sinónimos de categoría. Ninguna corrección borra filas, las 161036 filas originales sobreviven completas.

Las filas que repiten la combinación de mes, vía, frontera, país y tipo de viajero no son duplicados, difieren en la agrupación de residencia y cada una aporta viajeros distintos, así que se conservan y se suman. Un tercio de las filas trae decimales, que no son error sino estimaciones expandidas de encuesta, y se dejan tal cual.

2.2. Comportamiento temporal

La serie mensual tiene tres regímenes muy distintos. De 2009 a 2019 hay crecimiento sostenido, los visitantes pasan de 1.88 a 4.13 millones anuales. En 2020 llega el colapso de la pandemia, entre febrero y mayo la serie cae un 97 por ciento, de 317918 a 9779 visitantes en el mes, y el piso se mantiene casi dos años. Desde 2022 hay recuperación, pero a un nivel que parece quedar debajo de 2019, algo que la sección de análisis comparativo matiza. La figura 1 muestra la serie completa con la ventana de la pandemia y el cambio de metodología de 2023 marcados.




Figura 1: Ingreso mensual de viajeros, 2009 a junio 2026.

El componente estacional es fuerte y estable. Diciembre corre un 34 por ciento arriba del mes promedio, seguido de marzo y julio, mientras febrero y septiembre son los más bajos. El patrón se repite año con año y su amplitud crece con el nivel de la serie, lo que apunta a estacionalidad multiplicativa y anticipa que conviene modelar en logaritmo. La figura 2 resume el índice mensual y el mapa de calor por año.




Figura 2: Índice estacional y mapa de calor por año.

2.3. Comportamiento durante y después de la pandemia

El colapso de 2020 no fue solo una caída de nivel. Durante 2020 y 2021 los visitantes quedaron en el 25.6 y el 26.6 por ciento del nivel de 2019, y la estacionalidad desapareció por completo, esos dos años son casi planos sin el pico de diciembre. En 2022 la serie recupera su forma estacional habitual, lo que indica que el shock afectó el nivel de la serie y no su estructura. La figura 3 compara el perfil mensual de años seleccionados y deja ver esa pérdida y regreso del patrón anual.



05_pandemia.png

Figura 3: Perfil mensual de visitantes en años seleccionados.

2.4. Valores atípicos

El criterio del rango intercuartílico marca un solo mes atípico, diciembre 2019, que fue el pico histórico. Los meses del confinamiento no se marcan como atípicos, porque el colapso duró lo suficiente como para desplazar los propios cuartiles de la distribución. Por eso tratamos la pandemia como un cambio de régimen y no como puntos a depurar. La figura 4 muestra el diagrama de caja y la serie con los límites.




Figura 4: Distribución del total mensual y atípicos por rango intercuartílico.

2.5. Países, regiones, vías y fronteras

La demanda está muy concentrada. Tres países explican el 74.7 por ciento de los visitantes, El Salvador con 30.1, Guatemala con 29.7 y Estados Unidos con 14.9. Aparece aquí un punto importante, Guatemala figura porque la fuente cuenta a los residentes que regresan, y esa categoría desaparece por completo desde 2023 por el cambio de metodología. La figura 5 muestra el ranking de los diez principales países.




Figura 5: Diez principales países por visitantes acumulados.

Por regiones la concentración es aún mayor, tres regiones suman el 95.5 por ciento, América del Centro con 71.3, América del Norte con 19.6 y Europa con 4.6. Por vía de ingreso domina la terrestre con 59.1 por ciento sobre la aérea con 40.7, y la marítima es residual. Encontramos además que la vía marítima no registra ningún visitante desde 2017, todo su flujo quedó reclasificado como crucerista. Entre las fronteras, La Aurora concentra el 40.7 por ciento, seguida de Valle Nuevo con 21.7 y San Cristóbal con 9, las tres últimas terrestres con El Salvador (figura 6). Por tipo de viajero, turistas y excursionistas son estables en todo el rango, mientras Viajero cae en 2023 por reclasificación y los cruceristas terminan en 2022.




Figura 6: Ocho principales fronteras por visitantes acumulados.

3. Construcción de series y partición

Construimos siete series mensuales de visitantes. La obligatoria es el total. Como categorías de análisis elegimos regiones y fronteras, porque son las únicas dos opciones del enunciado cuyas tres series principales cubren los 210 meses sin huecos. Las series por país quedaban fuera porque Guatemala deja de reportarse en 2023, la vía marítima está en cero desde 2017 y los cruceristas terminan en 2022. El criterio de selección fue el acumulado de todo el período, como pide el enunciado. Las tres regiones son América del Centro, América del Norte y Europa, y las tres fronteras son La Aurora, Valle Nuevo y San Cristóbal.

La partición es temporal, 70 por ciento inicial para entrenamiento y 30 por ciento final para prueba. En series de tiempo la prueba debe ser posterior al entrenamiento, una partición aleatoria filtraría información del futuro. El corte cae en marzo 2021, el entrenamiento va de enero 2009 a marzo 2021 con 147 meses y la prueba de abril 2021 a junio 2026 con 63 meses. Este corte deja el colapso de la pandemia al final del entrenamiento y toda la recuperación en la prueba, lo que hace muy difícil el pronóstico y hay que tenerlo presente al leer las métricas. La figura 7 muestra las siete series y el corte.

Las siete series mensuales y el corte de la partición 70/30




Figura 7: Las siete series y el corte de la partición 70/30.

4. Análisis y modelado por serie

4.1. Procedimiento común

Cada serie se analizó igual. Las siete comparten inicio en enero 2009, frecuencia mensual y el mismo corte, con 147 meses de entrenamiento hasta marzo 2021. Se grafica cada una, se descompone y se discute la estacionariedad en media y en varianza. Todas resultan no estacionarias en media, por la tendencia y el colapso, y no estacionarias en varianza, la desviación móvil crece con el nivel. Por eso todas se modelan en logaritmo. Las dos regiones con meses en cero de 2020, América del Norte y Europa, usan logaritmo de uno más la serie, porque el logaritmo de cero no existe.

Para la estacionariedad en media usamos la función de autocorrelación y la prueba de Dickey-Fuller aumentada. En las siete series el ADF no rechaza en el nivel y sí rechaza tras una diferencia

regular, así que d vale uno. La diferencia estacional de período doce se decide caso por caso según los correlogramas y el ADF, el detalle por serie está en el cuadro 1. La figura 8 ilustra el procedimiento sobre el total.




Figura 8: Descomposición multiplicativa del total.

Serie	Transf.	ADF nivel (p)	ADF 1a dif (p)	d	Dif. estacional
Total	log	0.116	0.028	1	necesaria
Am. del Centro	log	0.200	0.036	1	necesaria
Am. del Norte	log1p	0.158	0.049	1	opcional
Europa	log1p	0.285	0.114	1	obligatoria
La Aurora	log	0.273	0.027	1	opcional
Valle Nuevo	log	0.195	0.000	1	opcional
San Cristóbal	log	0.253	0.912	1	obligatoria

Cuadro 1: Diagnóstico de estacionariedad por serie. El ADF no rechaza en el nivel en ninguna. En Europa y San Cristóbal la primera diferencia no basta, por eso su diferencia estacional es obligatoria.

Para elegir los parámetros p , q y d partimos de los correlogramas, el rezago 1 negativo sugiere un término de media móvil regular y el rezago 12 el término estacional. Alrededor de ese candidato airline ajustamos una rejilla de nueve modelos SARIMA por serie y comparamos por AIC, BIC y por la prueba de Ljung-Box sobre los residuos. Usamos también la función automática `auto_arima` como contraste. Falla en varias series porque su prueba de raíz unitaria lee el colapso como ausencia de tendencia y no diferencia, así que la selección automática necesita supervisión cuando hay un cambio de régimen.

Después comparamos cada SARIMA elegido contra Prophet, Holt-Winters con y sin amortiguamiento, suavizamiento exponencial simple y seasonal naive. El pronóstico estático de 63 meses resulta poco informativo, todos los modelos subestiman porque el entrenamiento termina en el piso

pandemico, así que agregamos una predicción a un paso tipo walk-forward, que mide el uso real de pronosticar el mes siguiente con el dato reciente. Las métricas de error son MAE y RMSE en la escala original de visitantes.

4.2. Resultados del modelado

El cuadro 2 resume, para las siete series, el modelo SARIMA elegido con su AIC y su BIC, el mejor modelo a un paso por MAE y el modelo seleccionado. El patrón es claro. Las series limpias, total, América del Centro, La Aurora y San Cristóbal, se modelan mejor con SARIMA. Las series que tocaron cero en 2020 o que quedaron en el piso al corte, América del Norte, Europa y Valle Nuevo, se pronostican mejor y de forma más robusta con seasonal naive.

Serie	SARIMA elegido	AIC	BIC	MAE 1 paso	Seleccionado
Total	$(0,1,1)(1,1,0)_{12}$	64.1	72.8	SARIMA 50430	SARIMA
Am. del Centro	$(0,1,1)(1,1,0)_{12}$	50.4	59.1	SARIMA 39151	SARIMA
Am. del Norte	$(0,1,1)(0,1,0)_{12}$	412.2	418.0	naive 13379	Seasonal naive
Europa	$(0,1,1)(0,1,0)_{12}$	341.6	347.4	naive 3018	Seasonal naive
La Aurora	$(0,1,1)(1,1,0)_{12}$	194.8	203.5	SARIMA 24747	SARIMA
Valle Nuevo	$(0,1,1)(1,1,0)_{12}$	323.2	331.9	naive 15692	Seasonal naive
San Cristóbal	$(1,1,1)(0,1,1)_{12}$	258.6	270.2	SARIMA 7137	SARIMA

Cuadro 2: Modelos por serie y selección final.

Dos observaciones importan. En las series limpias grandes el SARIMA gana a un paso en las dos métricas, sin ambigüedad, la estructura estacional le gana al simple año anterior. En las series con un bloque de ceros el logaritmo de uno más la serie vuelve frágil al SARIMA. En América del Norte el pronóstico a un paso incluso se dispara a un pico de 17.8 millones, porque el rezago estacional cae sobre los meses en cero y la diferencia en escala logarítmica explota al invertir. Por eso ahí el seasonal naive es la opción segura. Los residuos de las series limpias aprueban Ljung-Box, los de las series con ceros fallan por ese mismo bloque pandémico, no por mala especificación. Las figuras 9 y 10 muestran el diagnóstico y el pronóstico del total.




Figura 9: Diagnóstico de residuos del SARIMA elegido para el total.




Figura 10: Pronóstico estático de 63 meses del total contra la realidad.

5. Análisis comparativo

5.1. Regiones

Las respuestas del inciso comparativo para las tres regiones son las siguientes. La mayor estacionalidad la tiene América del Norte, con la banda más ancha y muy regular, aunque Europa la iguala en regularidad. La mayor tendencia de crecimiento es de América del Centro, que creció al 9.8 por ciento anual entre 2009 y 2019 contra 3.8 de Norte y 2.3 de Europa. La mayor volatilidad depende de la medida, por coeficiente de variación gana Centro por su amplitud, pero mes a mes las más

nerviosas son Europa y Norte. En cuanto a la pandemia, Norte y Europa cayeron a cero absoluto en abril 2020, más hondo que Centro, pero Centro tuvo el daño más sostenido con más meses debajo del 50 por ciento y la recuperación más lenta. La figura 11 resume el índice estacional y las curvas de recuperación.




Figura 11: Comparativo de las tres regiones.

5.2. Fronteras

Para las tres fronteras las respuestas son las siguientes. La mayor estacionalidad, la mayor tendencia y la mayor volatilidad son de San Cristóbal, la frontera que más creció y más oscila. La más afectada por la pandemia fue Valle Nuevo, con el mayor déficit acumulado y la recuperación más lenta, aunque La Aurora cayó más en el primer mes por el cierre aéreo total. La figura 12 muestra el detalle.




Figura 12: Comparativo de las tres fronteras.

5.3. Hallazgos para el INGUAT

El hallazgo principal es que la caída aparente del turismo frente a 2019 es en buena parte un artefacto de definición, no una realidad. América del Centro figura en 2025 con apenas el 66 por ciento de su nivel 2019, lo que sugeriría una recuperación fallida. Pero Guatemala pesaba el 52 por

ciento de esa región en 2019 y la metodología depurada dejó de contar a los residentes desde 2023. Al quitar Guatemala, la misma región está en el 139 por ciento de 2019, en línea con América del Norte con 139 y Europa con 125. Los tres mercados extranjeros ya superaron su nivel prepandemia. El INGUAT no debería leer el total crudo como estancamiento, debería reportar una serie de visitantes extranjeros reconciliada o marcar el quiebre de 2023.

Los demás hallazgos son los siguientes. La demanda está muy concentrada, tres regiones son el 95 por ciento y tres países el 75, con baja diversificación hacia mercados de larga distancia. La recuperación tuvo dos velocidades, el mercado aéreo reabrió primero y las fronteras terrestres casi un año después. Cada mercado tiene su propio calendario, Centro en diciembre, Norte en julio y Europa en la temporada de invierno del hemisferio norte, lo que permite planear campañas por temporada y por mercado. Sobre la predicción, las series grandes se pronostican bien a corto plazo con SARIMA y las pequeñas con métodos simples, pero ningún modelo entrenado con datos que incluyen el colapso sirve para pronóstico multianual sin reentrenar. Por último, el quiebre metodológico de 2023 debe documentarse y, en lo posible, empalmarse, porque afecta a Guatemala, a la categoría Viajero y a los cruceristas.

6. Conclusiones

El conjunto está en buen estado formal, sin faltantes ni duplicados, y su rejilla mensual está completa. Los problemas eran de consistencia de categorías y se corrigieron sin descartar datos. La serie tiene dos quiebres que dominan el modelado, la pandemia y el cambio de metodología de 2023, y ninguno es un atípico a depurar sino un cambio de régimen.

Las siete series comparten el mismo diagnóstico, no estacionarias en media ni en varianza, con estacionalidad fuerte de período doce, y se modelan en logaritmo con una diferencia regular y una estacional. Los modelos elegidos son variantes menores del candidato airline leído de los correlogramas. En la selección final las series limpias se quedan con SARIMA y las series con ceros o en el piso al corte con seasonal naive, un patrón consistente en las dos categorías.

La lectura más útil es que la recuperación del turismo receptivo es mejor de lo que sugiere el total crudo. Separando el efecto de la exclusión de residentes guatemaltecos, los mercados extranjeros ya superaron su nivel de 2019. Esa es la conclusión que más le serviría al INGUAT para no comunicar una caída que no ocurrió.